Universidad Santo Tomás
Facultad de Estadística – Estadística Multivariada
Docente: Edna Carolina Moreno

Proyecto
Análisis de Componentes Principales (ACP) sobre la base de datos Parkinsons (UCI)

Curso:	Análisis Multivariado
Estudiantes:	Santiago Rincón Jany (código 2428268) Valentina Reyes González (código 2461602)
Repositorio:	https://github.com/ValentinaReyes-785/Taller_ACP_Parkinsons
Notebook:	https://github.com/ValentinaReyes-785/Taller_ACP_Parkinsons/blob/main/Tall
Base de datos:	Parkinsons, UCI Machine Learning Repository https://archive.ics.uci.edu/dataset/174/parkinsons
Fecha de entrega:	15 de Octubre 2026

Índice

1. Justificación del conjunto de datos **2**

1.1. Contexto . . . 2

1.2. Pregunta de investigación . . . 2

1.3. Pertinencia del ACP . . . 2

2. Metodología **2**

3. Resultados **3**

3.1. Carga y exploración inicial . . . 3

3.2. Análisis descriptivo y correlaciones . . . 3

3.3. Preprocesamiento y estandarización . . . 5

3.4. Supuestos y pertinencia del ACP . . . 6

3.5. ACP "a mano" mediante DVS . . . 6

3.6. Selección del número de componentes . . . 7

3.7. Visualización . . . 7

3.8. Interpretación sustantiva de las componentes . . . 11

3.9. Proyección de las observaciones, patrones y atípicos . . . 12

4. Conclusiones y limitaciones **16**

4.1. Respuesta a la pregunta de investigación . . . 16

4.2. Información perdida . . . 16

4.3. Limitaciones . . . 16

4.4. Trabajo futuro . . . 17

5. Tabla de reutilización del código del profesor Pacheco **17**

1. Justificación del conjunto de datos

1.1. Contexto

La base *Parkinsons* proviene del repositorio UCI Machine Learning Repository y fue construida por [2] (Universidad de Oxford). Cada fila es **una grabación de voz** (vocal sostenida) de una persona; hay **195 grabaciones** (aproximadamente 6 por persona, de 31 personas) de personas con y sin enfermedad de Parkinson (`status`: 1 = Parkinson, 0 = sano). La Tabla 1 presenta el diccionario de variables.

Tabla 1: Diccionario de variables.

Variable	Descripción
`Fo`, `Fhi`, `Flo`	Frecuencia fundamental media, máxima y mínima (Hz)
`Jitter_pct`, `Jitter_Abs`, `Jitter_RAP`, `Jitter_PPQ`	Variación de la frecuencia fundamental
`Shimmer`, `Shimmer_dB`, `Shimmer_APQ3`, `Shimmer_APQ5`, `Shimmer_APQ`	Variación de la amplitud
`NHR`, `HNR`	Razón ruido/tonalidad
`RPDE`, `D2`	Medidas de complejidad no lineal
`DFA`	Exponente de escala fractal de la señal
`spread1`, `spread2`, `PPE`	Variación no lineal de la frecuencia fundamental
`Jitter_DDP`, `Shimmer_DDA`	Iguales a 3×`Jitter_RAP` y 3×`Shimmer_APQ3`
`status`	Parkinson (1) / sano (0)
`name`	Identificador de la grabación

1.2. Pregunta de investigación

¿Cómo se pueden resumir las variables acústicas de la voz mediante el Análisis de Componentes Principales y qué patrones de variabilidad y diferencias se observan entre las grabaciones de personas sanas y de personas con enfermedad de Parkinson?

1.3. Pertinencia del ACP

Esperamos una fuerte correlación debido a que varias medidas cuantifican lo mismo pero con fórmulas distintas. Al tener repetido el mismo fenómeno, hay redundancia en muchas de las 20 variables; justamente el ACP elimina la multicolinealidad y los efectos repetidos, y nos ayuda a resumir y visualizar más fácilmente lo que buscamos.

2. Metodología

El análisis se desarrolló en R, adaptando el código del profesor Mario Pacheco [1].

Matriz estandarizada y ponderada. Sea $X \in \mathbb{R}^{n\times p}$ la matriz de las $p = 20$ variables activas. Se construye Z con elementos

$$z_{ij} = \frac{1}{\sqrt{n-1}} \frac{x_{ij} - \bar{x}_j}{s_{x_j}}, \tag{1}$$

de modo que $Z^\top Z = R_x$, la matriz de correlaciones.

Descomposición en valores singulares. Se calcula $Z = P\Delta Q^\top$. Los valores propios son $\lambda_k = \delta_k^2$, las componentes principales son $F = ZQ = P\Delta$ y $\sum_{k=1}^{p} \lambda_k = p$. La inercia de la componente k es $100\,\lambda_k/p\,\%$.

Número de componentes. Se consideran el criterio de Kaiser ($\lambda_k > 1$), la inercia acumulada, el gráfico de sedimentación y la validación cruzada generalizada (GCV).

Interpretación. Se calculan $R_{cv} = \mathrm{cor}(Z, F)$, $\cos^2_{jk} = r^2_{jk}$ y $\mathrm{ctr}_{jk} = r^2_{jk}/\sum_j r^2_{jk}$, que se compara con $1/p = 5\,\%$.

Observaciones atípicas. Con las componentes estandarizadas $\tilde{f}_{ik}$ se calculan $d^2_{1i} = \sum_{k=1}^{p_1} \tilde{f}^2_{ik}$ y $d^2_{2i} = \sum_{k=p-q+1}^{p} \tilde{f}^2_{ik}$, y se marcan como atípicas las observaciones que superan el cuantil empírico de orden $1-\alpha$, con $\alpha = 0{,}05$. Se usó $p_1 = k = 4$ y $q \in \{1, 2\}$.

ACP robusto. Se compara con un ACP basado en la matriz de covarianzas del estimador de volumen mínimo del elipsoide (MVE) y con *projection pursuit*.

3. Resultados

3.1. Carga y exploración inicial

La base tiene 195 filas (147 grabaciones de personas con Parkinson y 48 de personas sanas) y no presenta valores faltantes. Cada columna es una medida acústica de las grabaciones, como la frecuencia o la amplitud.

Las 20 variables acústicas son activas porque construyen los ejes. `Jitter_DDP` y `Shimmer_DDA` provienen del mismo jitter y shimmer (son múltiplos exactos de `Jitter_RAP` y `Shimmer_APQ3`); incluirlos añadiría peso a algo que solo debe estar una vez, por lo que se toman como suplementarias. `status` también es suplementaria: indica la condición clínica, útil para explorar si los patrones acústicos difieren entre grupos, pero no se usa para construir los componentes.

Las 195 grabaciones provienen de solo 31 personas, por lo que las grabaciones de una misma persona se parecen entre sí. Las filas no son independientes y el tamaño muestral efectivo es bastante menor a 195.

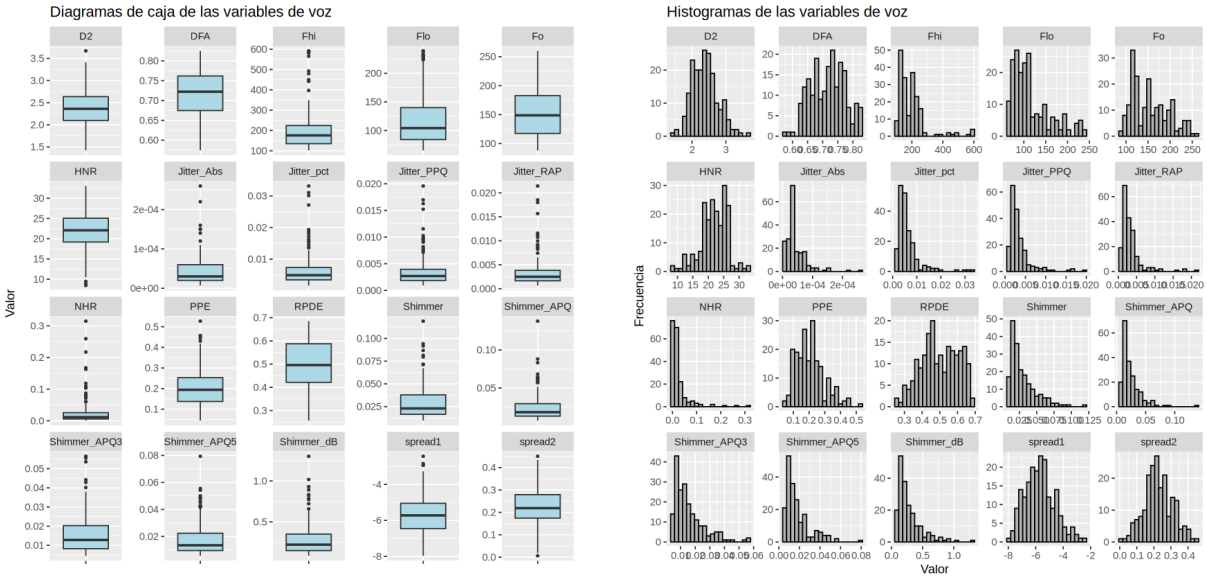
3.2. Análisis descriptivo y correlaciones

La Tabla 2 resume las variables activas y las Figuras 1 y 2 muestran su distribución y correlaciones.

Hay una fuerte asimetría a la derecha en NHR y en las variables de jitter (4,16 para NHR y 2,61, 3,31 y 3,04 para `Jitter_Abs`, `Jitter_RAP` y `Jitter_pct`, respectivamente); en Shimmer, Fhi, Flo y PPE es apenas moderada, HNR presenta una pequeña cola izquierda y el resto son prácticamente simétricas. NHR tiene un coeficiente de variación de aproximadamente 163 %, el mayor de todos, y jitter y shimmer son bastante dispersos. Estos valores afectarán desviaciones y correlaciones.

Tabla 2: Estadísticos descriptivos de las variables activas (CV en %).

Variable	Media	D.E.	Mín.	Q1	Mediana	Q3	Máx.	CV
Fo	154.2	41.39	88.33	117.6	148.8	182.8	260.1	26.8
Fhi	197.1	91.49	102.1	134.9	175.8	224.2	592	46.4
Flo	116.3	43.52	65.48	84.29	104.3	140	239.2	37.4
Jitter_pct	$6{,}22 \times 10^{-3}$	$4{,}85 \times 10^{-3}$	$1{,}68 \times 10^{-3}$	$3{,}46 \times 10^{-3}$	$4{,}94 \times 10^{-3}$	$7{,}37 \times 10^{-3}$	0.03316	77.9
Jitter_Abs	$4{,}40 \times 10^{-5}$	$3{,}48 \times 10^{-5}$	$7{,}00 \times 10^{-6}$	$2{,}00 \times 10^{-5}$	$3{,}00 \times 10^{-5}$	$6{,}00 \times 10^{-5}$	$2{,}60 \times 10^{-4}$	79.2
Jitter_RAP	$3{,}31 \times 10^{-3}$	$2{,}97 \times 10^{-3}$	$6{,}80 \times 10^{-4}$	$1{,}66 \times 10^{-3}$	$2{,}50 \times 10^{-3}$	$3{,}83 \times 10^{-3}$	0.02144	89.8
Jitter_PPQ	$3{,}45 \times 10^{-3}$	$2{,}76 \times 10^{-3}$	$9{,}20 \times 10^{-4}$	$1{,}86 \times 10^{-3}$	$2{,}69 \times 10^{-3}$	$3{,}96 \times 10^{-3}$	0.01958	80.1
Shimmer	0.02971	0.01886	$9{,}54 \times 10^{-3}$	0.0165	0.02297	0.03789	0.1191	63.5
Shimmer_dB	0.2823	0.1949	0.085	0.1485	0.221	0.35	1.302	69.0
Shimmer_APQ3	0.01566	0.01015	$4{,}55 \times 10^{-3}$	$8{,}25 \times 10^{-3}$	0.01279	0.02026	0.05647	64.8
Shimmer_APQ5	0.01788	0.01202	$5{,}70 \times 10^{-3}$	$9{,}58 \times 10^{-3}$	0.01347	0.02238	0.0794	67.3
Shimmer_APQ	0.02408	0.01695	$7{,}19 \times 10^{-3}$	0.01308	0.01826	0.0294	0.1378	70.4
NHR	0.02485	0.04042	$6{,}50 \times 10^{-4}$	$5{,}92 \times 10^{-3}$	0.01166	0.02564	0.3148	162.7
HNR	21.89	4.426	8.441	19.2	22.09	25.08	33.05	20.2
RPDE	0.4985	0.1039	0.2566	0.4213	0.496	0.5876	0.6852	20.8
DFA	0.7181	0.05534	0.5743	0.6748	0.7223	0.7619	0.8253	7.7
spread1	-5.684	1.09	-7.965	-6.45	-5.721	-5.046	-2.434	-19.2
spread2	0.2265	0.08341	$6{,}27 \times 10^{-3}$	0.1744	0.2189	0.2792	0.4505	36.8
D2	2.382	0.3828	1.423	2.099	2.362	2.636	3.671	16.1
PPE	0.2066	0.09012	0.04454	0.1375	0.1941	0.253	0.5274	43.6



(a) Diagramas de caja

(b) Histogramas

Figura 1: Distribución de las variables de voz.

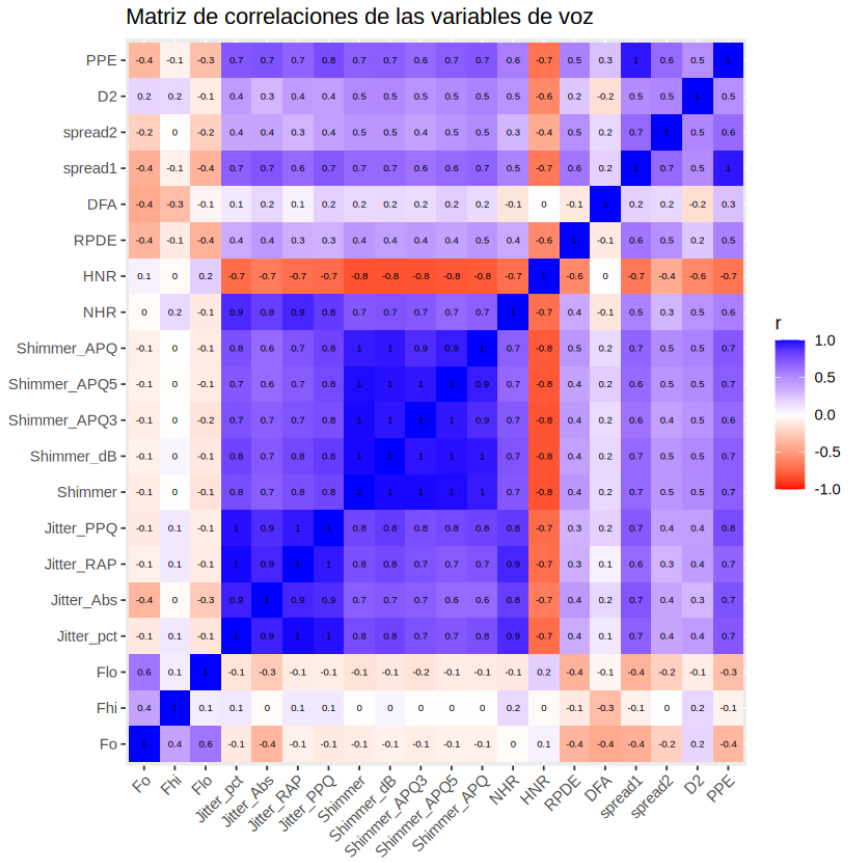


Figura 2: Mapa de calor de la matriz de correlaciones de las variables activas.

Lo más notable en el mapa de calor son jitter y shimmer, que consigo mismos (sus múltiplos) dan valores altos, de alrededor de 0,9 y 0,7 respectivamente. Se destaca también HNR, con valores altos pero en dirección contraria, y NHR, que sobresale sobre todo con jitter (podríamos considerar también `spread1` y PPE). Aparece otro bloque con Fo, Fhi y Flo, que se correlacionan algo entre sí pero muy poco con los principales (cerca de 0,15). El resto no aporta significativamente. Así, se distinguen tres niveles de bloques por importancia, dados por 1) ruido vocal y 2) nivel de frecuencia, más unos factores restantes difíciles de considerar. Por lo tanto, esperábamos cerca de 3 dimensiones subyacentes.

3.3. Preprocesamiento y estandarización

Con `na.omit` no se pierde ninguna observación (quedan las 195, más de las 100 requeridas). Se construyó Z con $n = 195$ y $p = 20$ y se verificó numéricamente que $Z^\top Z = R_x$.

Es necesario estandarizar por la gran diferencia de escalas entre variables: contrastar los 154 Hz de Fo contra 4×10^{-5} de `Jitter_Abs` muestra que el proceso es necesario. Con la matriz de covarianzas sin estandarizar dominarían los niveles de frecuencia (Fo, Fhi y Flo), por sus varianzas del orden de los miles frente a variables con valores varios órdenes por debajo de 1 (10^{-5}), concentrando prácticamente más del 99 % de la variabilidad total.

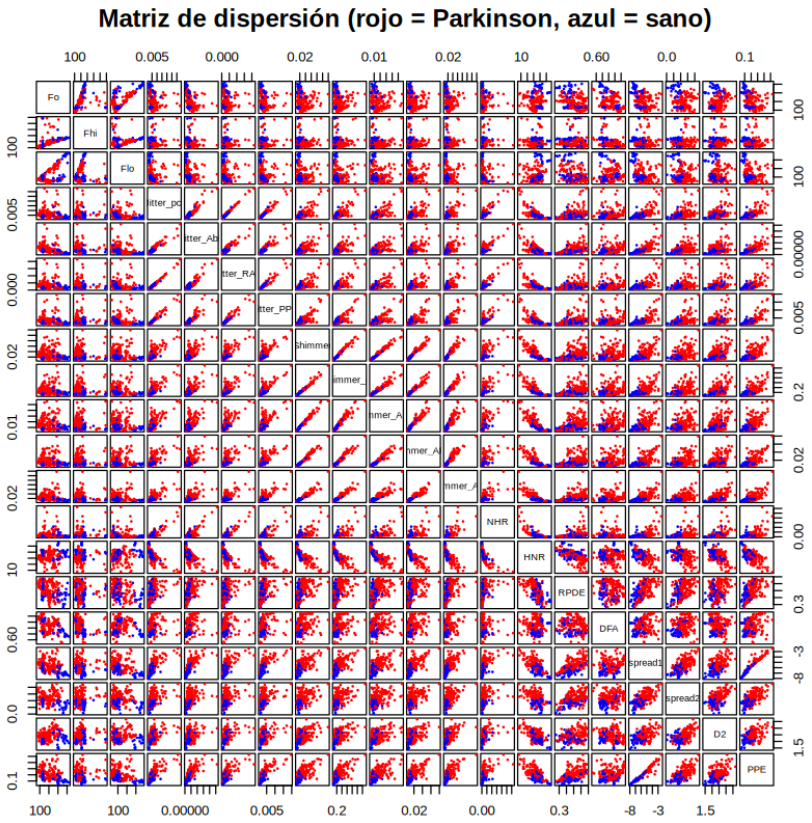


Figura 3: Matriz de dispersión de las variables activas (rojo: Parkinson; azul: sano).

3.4. Supuestos y pertinencia del ACP

El determinante de la matriz de correlaciones de las 22 variables es $4{,}22 \times 10^{-32}$ (casi singular por las dos relaciones exactas), y con las 20 activas es $8{,}79 \times 10^{-19}$, ambos cercanos a cero, lo que indica fuerte redundancia. Las razones `Jitter_DDP`/`Jitter_RAP` y `Shimmer_DDA`/`Shimmer_APQ3` están alrededor de 3. El KMO global es 0,86 y la prueba de Bartlett ($\chi^2 = 7754$, 190 g.l., $p < 0{,}001$) confirma que existen correlaciones entre las variables; sin embargo, variables como Fo (0,52), Fhi (0,62) y DFA (0,49) tienen KMO más bajos, lo que indica que no comparten tanta información con las demás.

El ACP supone relaciones principalmente lineales. Las variables de jitter, shimmer y NHR presentan asimetría y algunos valores extremos, por lo que una transformación logarítmica podría mejorar su comportamiento. `Jitter_DDP` y `Shimmer_DDA` quedaron como suplementarias porque son aproximadamente lo mismo que `Jitter_RAP` y `Shimmer_APQ3` multiplicado por 3, y al no aportar información adicional relevante no deben añadir más peso al análisis.

3.5. ACP "a mano" mediante DVS

Se obtuvo la DVS de Z y se verificó numéricamente que $F = P\Delta$, $Q^\top Q = I_p$, $\sum \lambda_k = p$, que $\mathrm{Var}(F_k) \propto \lambda_k$ y que las componentes son incorrelacionadas. Al comparar con `eigen(cor(...))`, los valores propios coinciden y algunas columnas de Q aparecen con signo cambiado: `svd()` y `eigen()` son dos funciones distintas que llegan a lo mismo por métodos diferentes, y cada una

escoge un sentido distinto para representar el mismo eje; es solo una orientación y la varianza explicada por cada componente es la misma.

3.6. Selección del número de componentes

Tabla 3: Valores propios e inercia (primeras 8 componentes).

Componente	Valor propio	Inercia (%)	Acumulada (%)
1	11.3	56.67	56.7
2	2.44	12.20	68.9
3	1.5	7.52	76.4
4	1.29	6.43	82.8
5	0.927	4.63	87.5
6	0.708	3.54	91.0
7	0.551	2.75	93.7
8	0.359	1.80	95.5

Tabla 4: Número de componentes sugerido por cada criterio.

Criterio	k sugerido
Kaiser ($\lambda_k > 1$)	4
Inercia acumulada $\geq 70\,\%$	3
Inercia acumulada $\geq 80\,\%$	4
Validación cruzada (GCV)	8

El k elegido es 4, por el criterio de Kaiser y por la inercia acumulada, que con cuatro componentes alcanza 82,8 %. Escoger 5 sería incorrecto porque su valor propio es menor que 1 (0,93), y escoger 3 es viable en nuestra opinión, pero si dos indicadores sugieren 4 hay evidencia estadística de un método más eficiente que recoge suficiente varianza sin ser excesivo.

3.7. Visualización

El biplot permite ver 1) qué variables caracterizan específicamente a qué grabaciones y 2) la estructura de correlaciones y la posición de los grupos. Su limitación es qué tan bien está representada cada variable en los componentes: al tener 20 variables, la inercia por componente será baja (en el primer plano es 68,9 %), y tantas variables son difíciles de representar por completo con pocos componentes. La mala representación da aproximados, y además hay que tener cuidado por la dependencia de las filas (las personas se repiten).

El primer plano (CP1–CP2) muestra cómo se acercan al CP1 las variables principales: jitter, shimmer, NHR, `spread1` y PPE (con $\cos^2$ entre 0,68 y 0,88), con HNR alto también pero en sentido completamente opuesto. Los otros planos (CP1–CP3 y CP2–CP3) casi no separan los grupos: ayudan a discriminar la estructura de las variables, pero no a discriminar entre grupos. Con estos componentes no alcanzan a estar bien representadas Fo, Fhi, Flo y DFA.

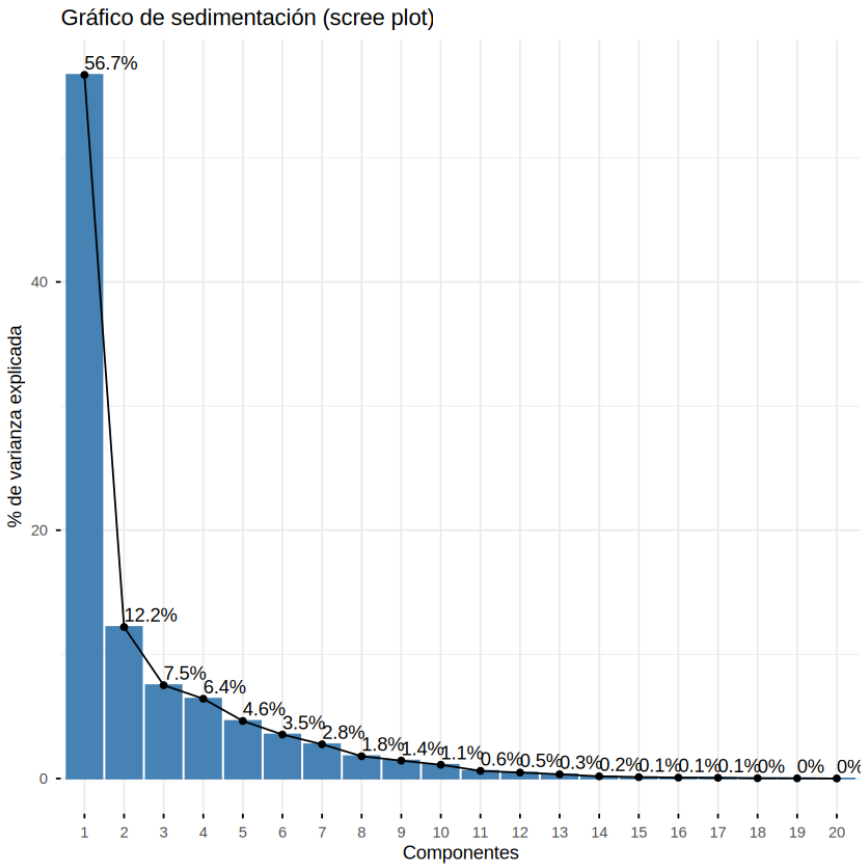
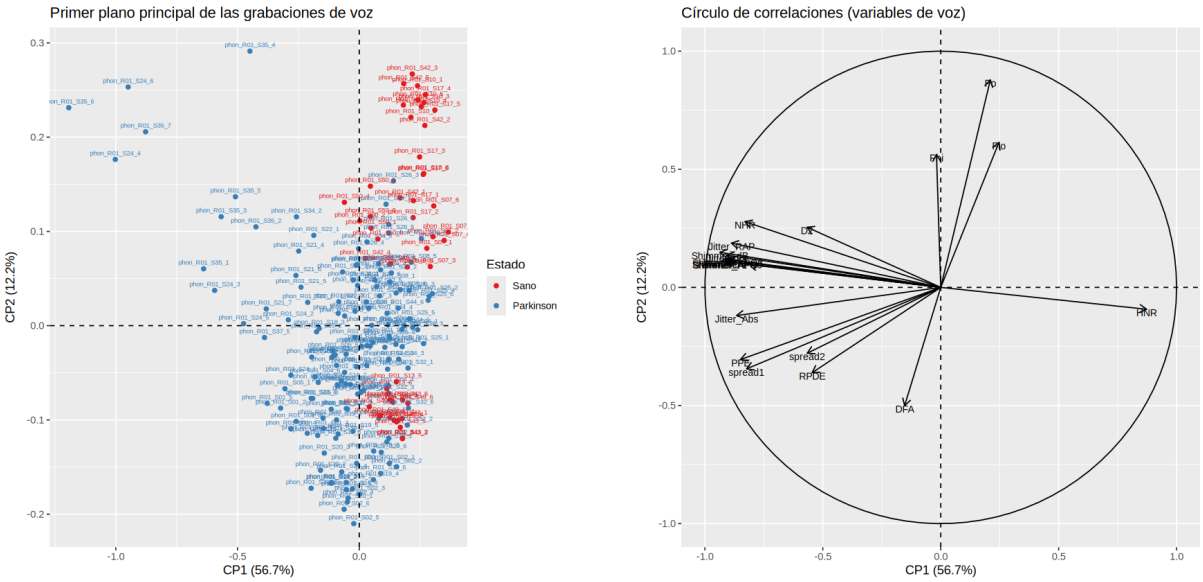


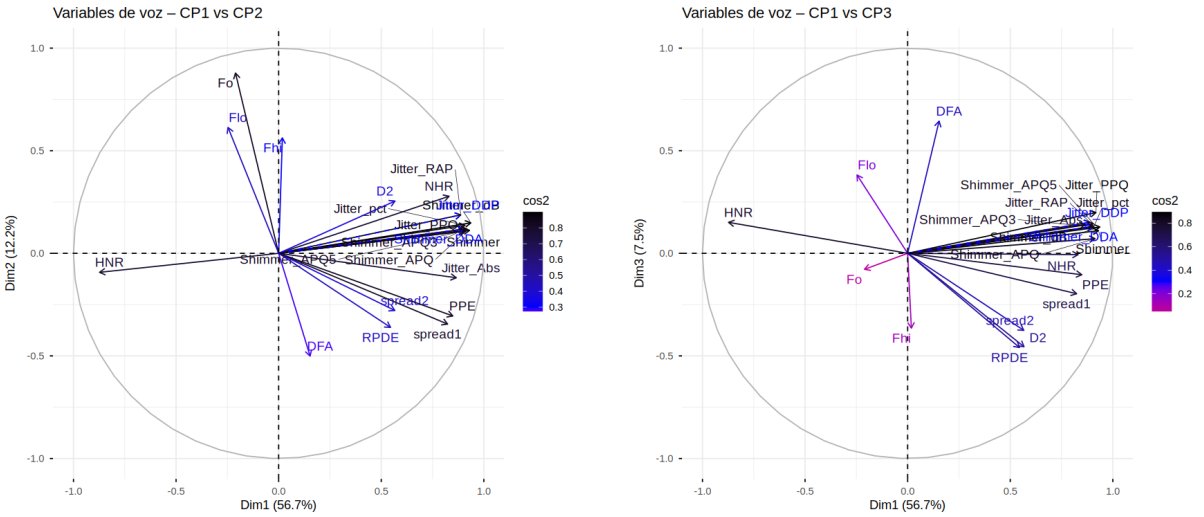
Figura 4: Gráfico de sedimentación.



(a) Plano de las grabaciones

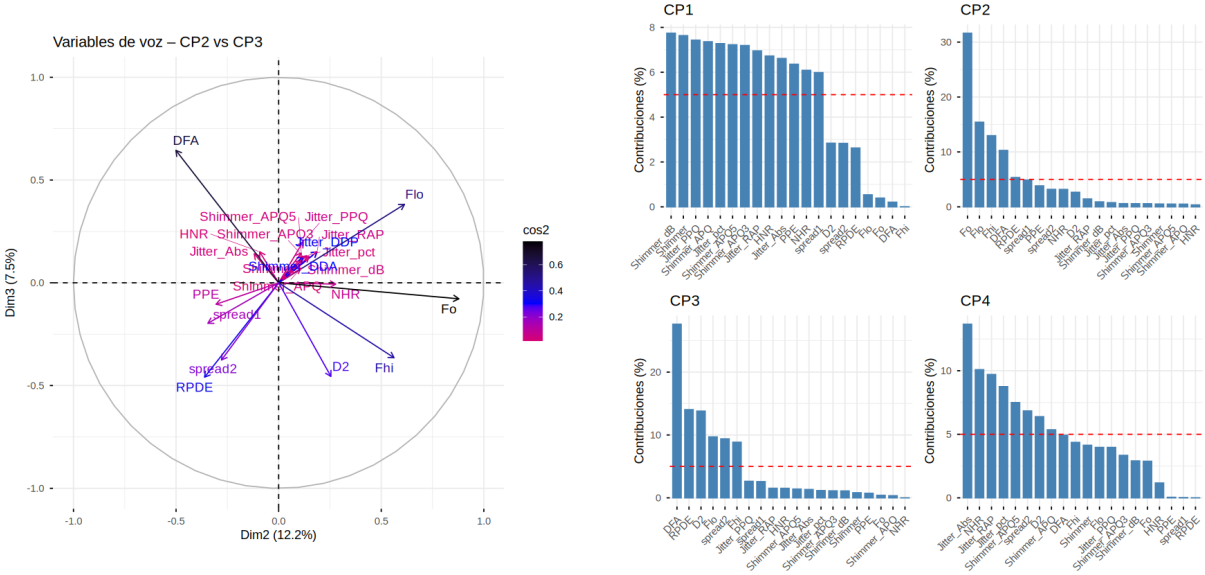
(b) Círculo de correlaciones

Figura 5: Gráficos "a mano" con `ggplot2`.



(a) CP1 vs CP2 (b) CP1 vs CP3

Figura 6: Variables coloreadas por $\cos^2$ (planos 1–2 y 1–3).

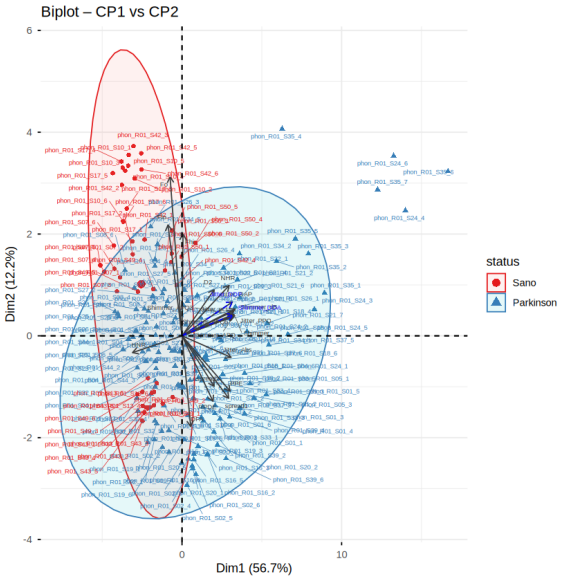


(a) CP2 vs CP3 (b) Contribuciones

Figura 7: Variables en el plano 2–3 y contribuciones a CP1–CP4.

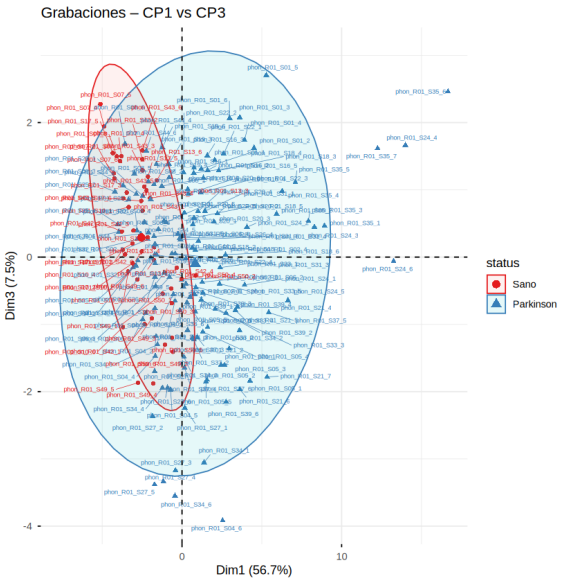


(a) CP1 vs CP2



(b) Biplot CP1 vs CP2

Figura 8: Grabaciones y biplot en el plano 1–2.

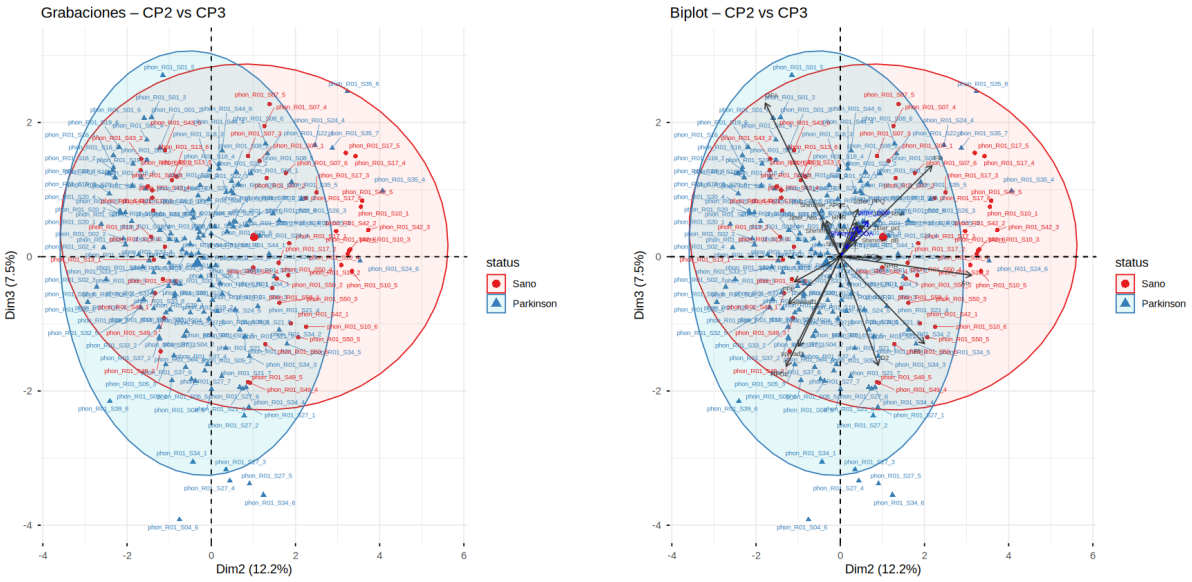


(a) CP1 vs CP3



(b) Biplot CP1 vs CP3

Figura 9: Grabaciones y biplot en el plano 1–3.



(a) CP2 vs CP3 (b) Biplot CP2 vs CP3

Figura 10: Grabaciones y biplot en el plano 2–3.

3.8. Interpretación sustantiva de las componentes

Las Tablas 5 y 6 presentan, para las cuatro componentes retenidas, los loadings Q, las correlaciones variable–componente R_{cv}, el $\cos^2$ y las contribuciones (en %). En negrilla aparecen los $\cos^2 > 0{,}3$ y las contribuciones mayores que $1/p = 5\,\%$.

Tabla 5: Loadings (Q) y correlaciones variable–componente (R_{cv}).

	Loadings Q				Correlaciones R_{cv}			
Variable	CP1	CP2	CP3	CP4	CP1	CP2	CP3	CP4
`Fo`	0.062	0.562	-0.064	0.170	0.210	0.878	-0.078	0.192
`Fhi`	-0.005	0.360	-0.297	-0.209	-0.018	0.562	-0.365	-0.237
`Flo`	0.073	0.393	0.311	0.199	0.247	0.613	0.382	0.226
`Jitter_pct`	-0.270	0.087	0.108	-0.296	-0.908	0.137	0.132	-0.335
`Jitter_Abs`	-0.257	-0.076	0.115	-0.370	-0.866	-0.119	0.141	-0.419
`Jitter_RAP`	-0.264	0.120	0.123	-0.311	-0.888	0.187	0.151	-0.353
`Jitter_PPQ`	-0.273	0.076	0.162	-0.199	-0.918	0.118	0.199	-0.226
`Shimmer`	-0.276	0.071	0.090	0.203	-0.930	0.112	0.110	0.231
`Shimmer_dB`	-0.278	0.095	0.105	0.170	-0.937	0.148	0.128	0.193
`Shimmer_APQ3`	-0.268	0.075	0.105	0.183	-0.903	0.118	0.129	0.207
`Shimmer_APQ5`	-0.269	0.071	0.118	0.274	-0.905	0.110	0.145	0.310
`Shimmer_APQ`	-0.271	0.070	0.058	0.231	-0.913	0.109	0.071	0.262
`NHR`	-0.247	0.178	-0.005	-0.318	-0.831	0.278	-0.006	-0.360
`HNR`	0.259	-0.059	0.123	-0.108	0.873	-0.093	0.151	-0.123
`RPDE`	-0.162	-0.231	-0.375	0.003	-0.545	-0.361	-0.459	0.003
`DFA`	-0.046	-0.321	0.526	0.222	-0.153	-0.501	0.644	0.252
`spread1`	-0.245	-0.221	-0.161	-0.014	-0.824	-0.345	-0.197	-0.016
`spread2`	-0.168	-0.178	-0.306	0.262	-0.566	-0.279	-0.376	0.296
`D2`	-0.168	0.163	-0.371	0.253	-0.567	0.255	-0.455	0.286
`PPE`	-0.252	-0.195	-0.085	0.021	-0.849	-0.305	-0.104	0.023

CP1. En el mismo signo se agrupan el cambio de frecuencia (los jitter), la amplitud (los shimmer), la cantidad de ruido (NHR), `spread1` y PPE, con HNR en el sentido opuesto. El eje creado contrasta ruido vocal frente a una voz limpia y armónica. CP1 contiene el 56,7 % de la variabilidad; los centroides están en $-2{,}55$ (sano) y $+0{,}83$ (Parkinson), lo que muestra que las personas

Tabla 6: Calidad de representación ($\cos^2$) y contribuciones (%) de las variables.

	$\cos^2$				Contribución (%)			
Variable	CP1	CP2	CP3	CP4	CP1	CP2	CP3	CP4
Fo	0.044	**0.772**	0.006	0.037	0.39	**31.62**	0.40	2.88
Fhi	0.000	**0.316**	0.133	0.056	0.00	**12.96**	**8.85**	4.36
Flo	0.061	**0.376**	0.146	0.051	0.54	**15.42**	**9.69**	3.97
Jitter_pct	**0.825**	0.019	0.017	0.112	**7.27**	0.76	1.16	**8.75**
Jitter_Abs	**0.750**	0.014	0.020	0.176	**6.61**	0.58	1.33	**13.70**
Jitter_RAP	**0.788**	0.035	0.023	0.125	**6.95**	1.44	1.52	**9.70**
Jitter_PPQ	**0.842**	0.014	0.040	0.051	**7.43**	0.57	2.63	3.97
Shimmer	**0.865**	0.012	0.012	0.053	**7.63**	0.51	0.81	4.14
Shimmer_dB	**0.877**	0.022	0.017	0.037	**7.74**	0.90	1.10	2.91
Shimmer_APQ3	**0.815**	0.014	0.017	0.043	**7.19**	0.57	1.11	3.34
Shimmer_APQ5	**0.819**	0.012	0.021	0.096	**7.23**	0.50	1.40	**7.50**
Shimmer_APQ	**0.834**	0.012	0.005	0.069	**7.36**	0.49	0.34	**5.35**
NHR	**0.690**	0.077	0.000	0.130	**6.09**	3.17	0.00	**10.10**
HNR	**0.762**	0.009	0.023	0.015	**6.72**	0.35	1.51	1.17
RPDE	0.297	0.130	0.211	0.000	2.62	**5.34**	**14.03**	0.00
DFA	0.023	0.251	**0.415**	0.063	0.21	**10.28**	**27.62**	4.93
spread1	**0.678**	0.119	0.039	0.000	**5.98**	4.88	2.58	0.02
spread2	**0.321**	0.078	0.141	0.088	2.83	3.18	**9.38**	**6.84**
D2	**0.322**	0.065	0.207	0.082	2.84	2.66	**13.80**	**6.39**
PPE	**0.721**	0.093	0.011	0.001	**6.36**	3.82	0.73	0.04

con Parkinson tienden, en promedio, a tener más inestabilidad vocal.

CP2. Se enfoca ya no tanto en el ruido y lo limpio sino en la frecuencia, principalmente con Fo, Fhi y Flo. CP2 contiene el 12,2 % de la variabilidad. Las voces con puntaje alto son de tono más alto y de dinámica menos irregular; las de puntaje bajo son más graves y con mayor irregularidad. Los grupos quedan en +1,02 (sano) y −0,33 (Parkinson), de modo que los sanos puntúan más alto. Es importante resaltar que no se separa por sexo, factor bastante influyente en la frecuencia, por lo que se debe tener cuidado al analizar este componente.

CP3 y CP4. CP3 contiene el 7,5 % de la variabilidad y CP4 el 6,4 %. Este componente distingue principalmente si la inestabilidad de una voz proviene sobre todo de la amplitud (shimmer) o de la frecuencia/ruido (jitter, NHR), una vez descontado el análisis del CP1.

3.9. Proyección de las observaciones, patrones y atípicos

Se calcularon el $\cos^2$ y la contribución de cada grabación. Las mejor representadas en el plano 1–2 son S35_7, S35_6, S32_2, S35_3 y S10_1. Las que más contribuyen a CP1 son S35_6 (12,6 %), S24_4, S24_6, S35_7 y S35_1.

Se ubican tres grabaciones concretas. S35_6 es la de valor más extremo en CP1 (indicador $I_1 = 1{,}000$; aporta 12,6 % de la inercia de CP1) y además es atípica en d_1^2 (32,9) y en d_2^2 (con $q = 1$ y $q = 2$); es una voz que resalta por tener una combinación de variables bastante inusual frente al resto. S24_4 también es extrema en CP1 ($I_1 = 0{,}91$; la grabación S24_6 tiene 0,885) y en CP4 ($I_4 \approx 0$; contribuyen 11,4 % y 11,2 % de esa componente), con d_1^2 cercano a 43; en esa grabación los valores de amplitud y de frecuencia/ruido se desvían en direcciones opuestas. S07_5, junto con S07_4, S07_6 y S07_2, ocupa los valores más bajos de I_1 (0,26–0,29), es decir, las voces más estables y limpias de la base; que 4 de las 5 grabaciones más bajas sean de la misma persona muestra la dependencia entre grabaciones y que hay que mirarlo con delicadeza.

Tabla 7: Indicador I_1: cinco grabaciones con valores mínimos y máximos.

Mínimos		Máximos	
S07_5	0,262	S35_6	1,000
S07_4	0,270	S24_4	0,910
S17_5	0,288	S24_6	0,885
S07_6	0,290	S35_7	0,851
S07_2	0,292	S35_1	0,738

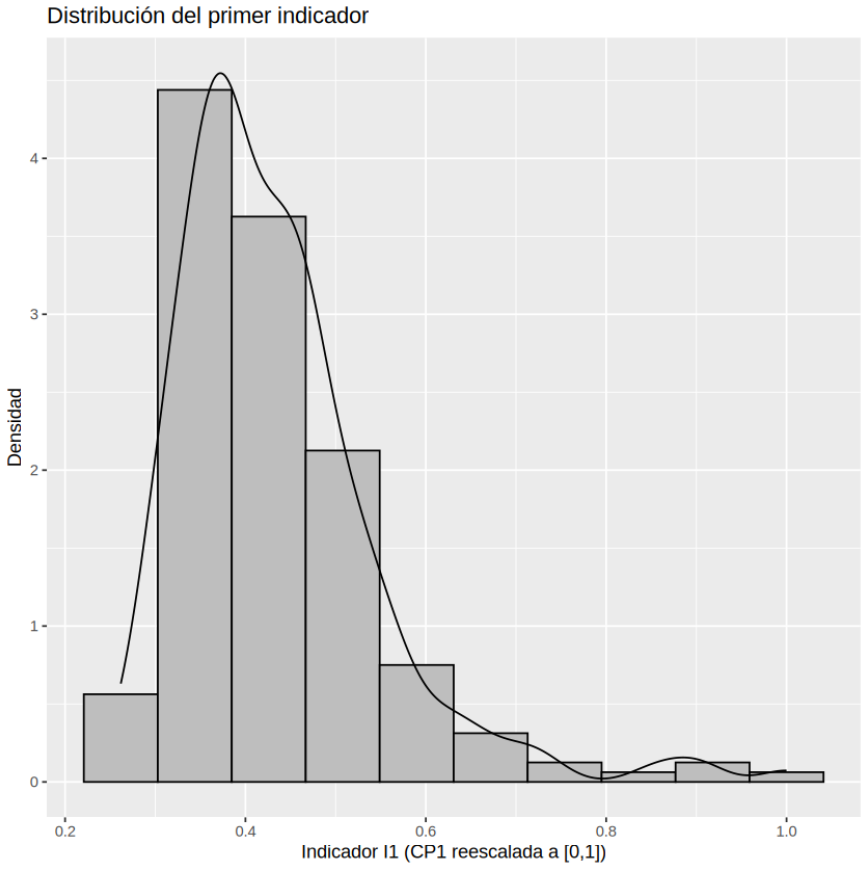


Figura 11: Histograma y densidad del indicador I_1.

Atípicos. Con $\alpha = 0{,}05$ y $p_1 = k = 4$, d_1^2 marca 9 grabaciones (cuantil 9,78): `S04_6`, `S21_7`, `S22_1`, `S24_4` (43,1), `S24_6` (42,6), `S35_1`, `S35_4`, `S35_6` (32,9) y `S35_7`. Con d_2^2 y $q = 1$ (cuantil 5,33) se marcan `S01_6`, `S05_2`, `S18_3`, `S20_2`, `S22_3`, `S35_6`, `S37_5`, `S39_1` y `S39_2` (27,7); con $q = 2$ (cuantil 8,01), `S20_2`, `S22_3`, `S24_5`, `S24_6`, `S35_6`, `S37_5`, `S39_1`, `S39_2` y `S50_4` (29,5).

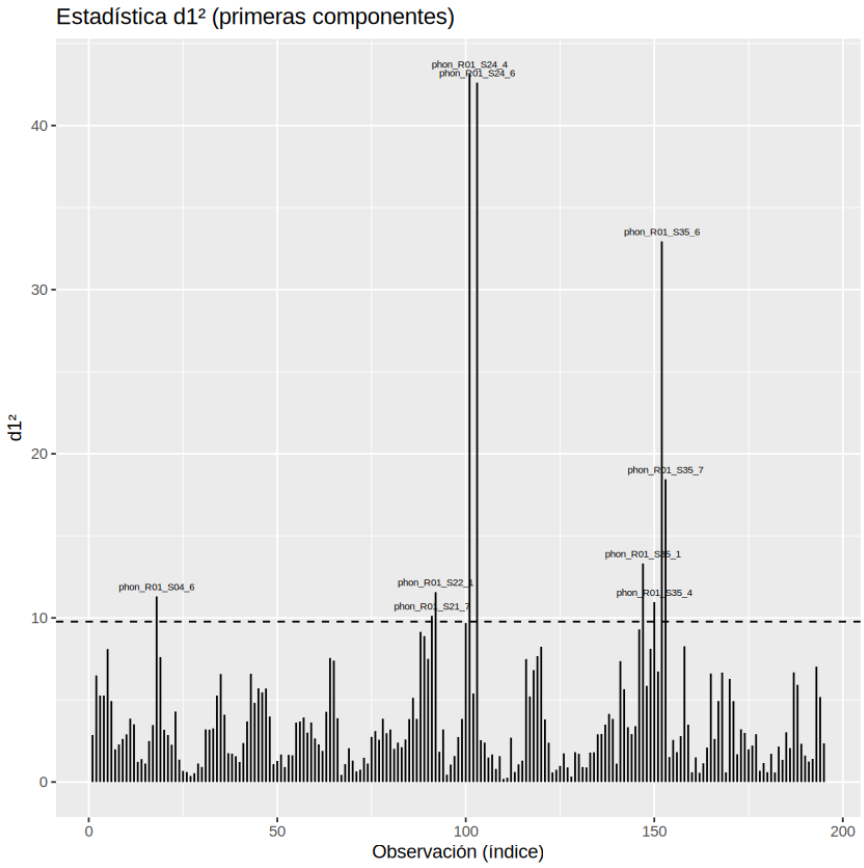
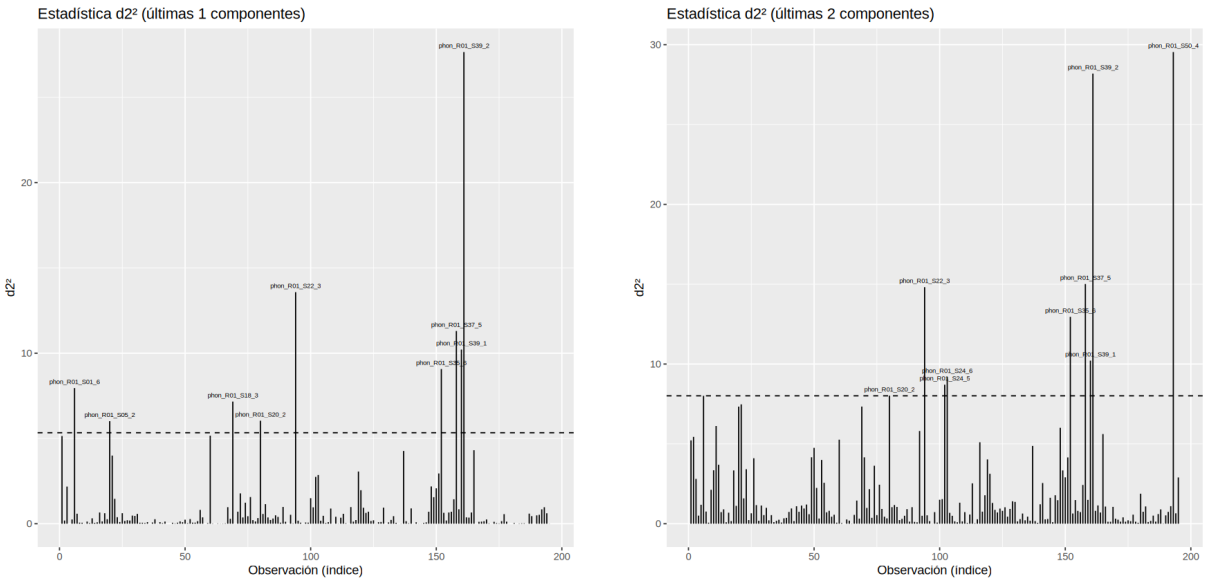


Figura 12: Estadística d_1^2 (primeras componentes).

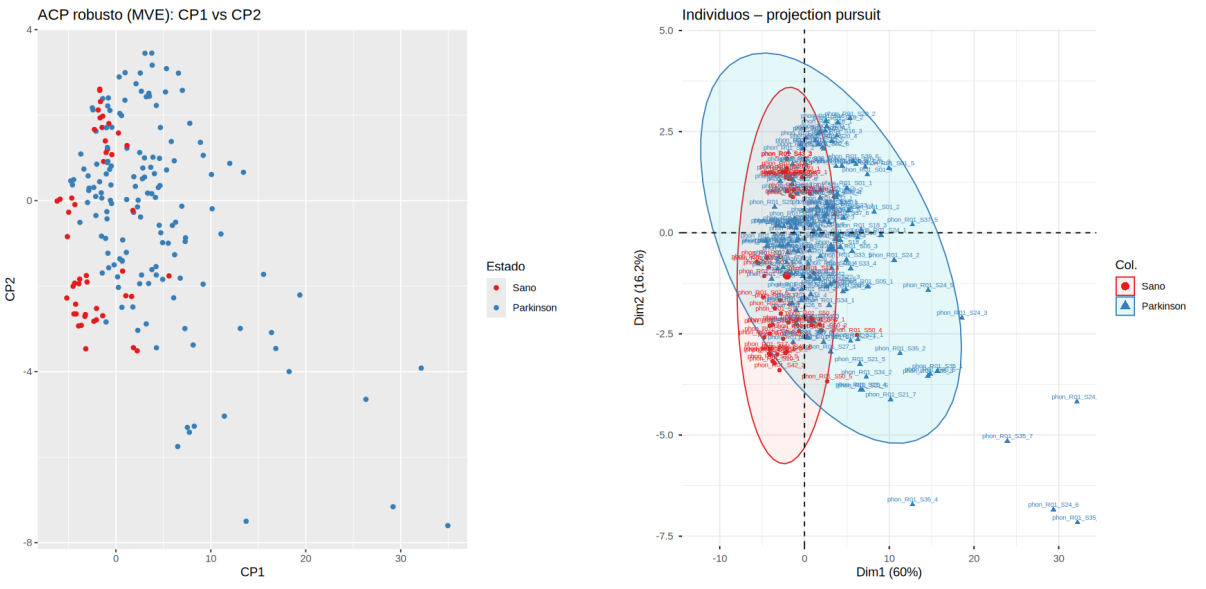
ACP robusto. Los resultados del ACP robusto (MVE) y de *projection pursuit* se muestran en las Figuras 14 y 15. Con projection pursuit, la primera dimensión explica el 60,0 % de la varianza.

Las diferencias entre d_1^2 y d_2^2: ambas son distancias calculadas con los componentes estandarizados, pero sobre grupos distintos. d_1^2 usa las primeras p_1 componentes, que poseen mayor varianza, e identifica las grabaciones mucho más lejanas del valor central dentro del patrón principal. Por el contrario, d_2^2 usa las últimas q componentes, que casi no poseen varianza: si es alta, la grabación rompe con la estructura de correlación, no es una combinación normal, aunque pueda verse normal en el primer plano. Sobre los valores atípicos, el código usa un cuantil con $\alpha = 0{,}05$, así que siempre marcará ese 5 % de las 195 grabaciones; por ello el número marcado no prueba que haya atípicos. El ACP robusto, al calcular el centro y la dispersión de forma resistente, reduce el efecto de la influencia de los valores atípicos.



(a) $q = 1$ (b) $q = 2$

Figura 13: Estadística d_2^2 (últimas componentes).



(a) ACP robusto (MVE) (b) Projection pursuit

Figura 14: Plano principal de los métodos robustos.

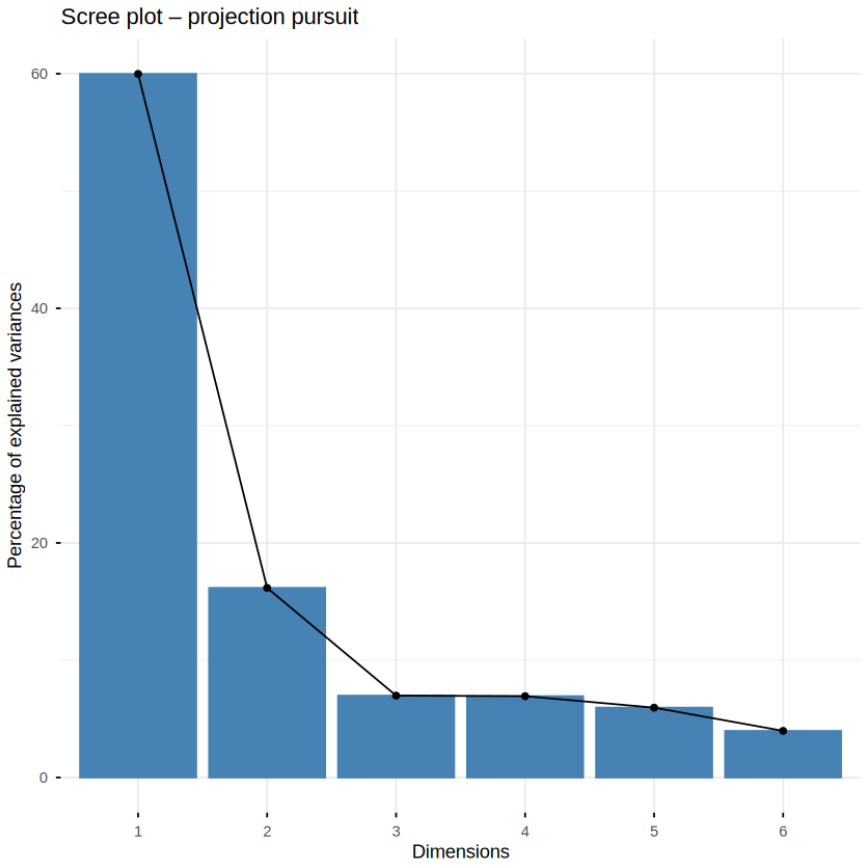


Figura 15: Gráfico de sedimentación del ACP por projection pursuit.

4. Conclusiones y limitaciones

4.1. Respuesta a la pregunta de investigación

Respondiendo a nuestra pregunta de investigación, sí es posible resumir las 20 variables acústicas con el ACP, con un total de 4 componentes principales que explican el 82,8 % de la variabilidad. Se identificaron patrones a través de los componentes (sobre todo el primero) para diferenciar si la persona tenía Parkinson: tienden a tener mayor inestabilidad vocal y sus voces son más graves e irregulares (CP2).

4.2. Información perdida

La inercia perdida con $k = 4$ es del 17,2 %, que nos parece bastante aceptable porque la decisión de $k = 4$ está fundamentada y un $k = 5$ solo aumentaría 4,6 puntos la inercia acumulada.

4.3. Limitaciones

Consideramos cuatro limitaciones principales: (1) **Dependencia**: 195 grabaciones de solo 31 personas, de modo que las filas no son independientes y el tamaño muestral efectivo es mucho menor, lo que hace que las pruebas KMO/Bartlett y las elipses se vean infladas. (2) **Atípicos influyentes**: cuatro grabaciones de dos personas generan aproximadamente el 36 % de la inercia de CP1. (3) **Clases desbalanceadas**: 147 con Parkinson frente a 48 sanos. (4) **Redundancia**

exacta entre medidas (visible en jitter y shimmer), que infla el peso del bloque de inestabilidad en CP1.

4.4. Trabajo futuro

Sería interesante aplicar la transformación logarítmica a las variables asimétricas; corregir la dependencia de las grabaciones trabajando a nivel de persona y no de grabación (y, para aumentar el tamaño muestral, incluir más personas, lo que fundamenta mejor los procesos estadísticos); y, por último, incorporar el sexo de las personas (y posiblemente la edad) para analizar mejor el componente de frecuencia (CP2).

5. Tabla de reutilización del código del profesor Pacheco

Tabla 8: Reutilización y adaptación del código del profesor Pacheco.

Etapa	Punto	Código original	Adaptación a Parkinsons
Importación	1	`read_excel` + `column_to_rownames(Çountry")` + factores	`read.csv`, `name` como nombre de fila, `status` como factor
Casos completos / Z	3	`na.omit(wdi)`; `select_if(is.numeric)...`/`(sd*sqrt(n-1))`	solo `vars_voz` (20)
DVS, F, R_{cv}, $\cos^2$, ctrv, ctri	5, 7, 8, 9	`svd(Z)`, `Z%*%Q`, `cor(Z,F)`	nombres, ejes, títulos
ACP FactoMineR	6–7	`PCA(...,` `quali.sup=c(1,2), ncp=4)`	`quali.sup=1`, `quanti.sup=22:23`, `ncp=p`
factoextra	7	`fviz_*`, `habillage=2`	`habillage=1` (`status`)
GCV, indicadores, d_1^2/d_2^2, robusto, PP	6, 9	`estim_ncp`, `indicadores()`, `d12`, `d22`, `cov.rob`, `PCAproj`	k, p_1, q propios, ids de grabación

Referencias

[1] Pacheco, M. (s.f.). *Análisis Multivariado* [Repositorio de código y material de clase]. Recuperado de https://datastatistic.github.io/multivariate/

[2] Little, M. A., McSharry, P. E., Roberts, S. J., Costello, D. A. E. y Moroz, I. M. (2007). Exploiting nonlinear recurrence and fractal scaling properties for voice disorder detection. *BioMedical Engineering OnLine*, 6, 23.

[3] Husson, F., Lê, S. y Pagès, J. (2017). *Exploratory Multivariate Analysis by Example Using R* (2.ª ed.). CRC Press.

[4] Johnson, R. A. y Wichern, D. W. (2007). *Applied Multivariate Statistical Analysis* (6.ª ed.). Pearson.